

Détection et classification de fractures osseuses

Ewen Le Bihan

2021-12-20

Professeurs encadrants du candidat

— M. Chireux

— M. Lauront

1 Ancrage au thème

Les fractures osseuses constituent une catégorie de blessures assez communes mais potentiellement graves, avec des conséquences parfois permanentes sur la suite de la vie du patient. Plus particulièrement, la détection et classification de fractures osseuses constitue une étape essentielle du traitement de tels blessures.

(⁴⁵/50 mots)

2 Motivation du choix

Il convient de s'intéresser à l'automatisation du processus de détection et de classification de telles blessures, afin de fluidifier l'orientation dans un service hospitalier. En effet, les hopitaux sont ces derniers temps souvent en sous-effectif, et fournir un premier diagnostic sans intervention professionnelle pourrait améliorer la situation.

(⁴⁸/50 mots)

3 Positionnements thématiques

— *INFORMATIQUE (Traitement d'images)*

- *INFORMATIQUE (Apprentissage automatique)*
- *MATHÉMATIQUES (Trigonométrie)*

4 Mots-clés

Français	English
Fracture osseuse	Bone fracture
Détection des bords	Edge detection
Apprentissage automatique	Machine learning
Réseau neuronal convolutif	Convolutional neural network
Vectorisation	Vectorization

5 Bibliographie commentée

La détection automatisée de maladies et blessures, et, plus particulièrement, de fractures osseuses, est devenue envisageable ces derniers temps. En effet, l'université américaine de Stanford a organisé en 2018 une compétition — «MURA» — visant à encourager la création d'algorithmes détectant des fractures. Ils ont mis à disposition une large base de données d'exemples pour permettre aux réseaux neuronaux programmés par les candidats de s'entraîner. Les résultats de cette compétition montre qu'un réseau neuronal peut dépasser les capacités d'un être humain avec une dizaine d'années d'expérience[8].

Une année plutôt, William Gale et. al. mettent à profit le même principe de réseaux neuronaux afin de détecter des fractures du bassin[3]. Ils utilisent trois réseaux neuronaux convolutifs (*CNN*) consécutifs pour réduire le nombre d'images et la taille de celles-ci, en ne sélectionnant que les régions où une fracture est possible, puis un dernier réseau pour effectuer la détection. Les résultats montrent une amélioration de la précision du réseau par rapport à des essais antérieurs

Les deux exemples d'utilisation d'apprentissage automatique dans le cadre de la reconnaissance de fractures mentionnés précédemment partagent un point commun : le nombre d'images radiographiques nécessaire à l'entraînement de tels réseaux est assez conséquent : MURA[9] est un set de 40 561 images tirées de 14 863 études, et le réseau de William Gale et. al. s'est entraîné sur 53 278 images – l'entièreté des images de bassins capturées par l'Hôpital *Royal Adelaide* entre 2005 et 2015[3].

Chacune de ces images, pour pouvoir être utile à l'apprentissage, doit être étiquetée au préalable : «

y’a-t-il présence de fracture dans cette image ? ». De plus, la question de la diversité et de l’inclusivité du set de données collecté (« Représente-t-il correctement et justement la population globale ? ») peut s’avérer complexe[5].

De plus, ces réseaux ne peuvent répondre avec fiabilité qu’à la question de *présence* d’une fracture, la question d’une *classification* quelconque demanderait donc une taille de set d’entraînement bien plus grande et difficilement atteignable.

De surcroît, il existe des centaines de classifications différentes – certaines avec un champ d’application assez réduit. Par exemple,

- la classification Garden[6] ne concerne que les fractures du bassin ;
- la classification SALTER[7] catégorise les fractures chez l’enfant en fonction de l’atteinte au cartilage de croissance, ce qui a un effet conséquent : dans le type le plus grave, c’est-à-dire l’effacement du cartilage par écrasement, le patient pourrait avoir une différence de longueur entre ses deux jambes.

Mais l’apprentissage automatique n’est pas la seule potentielle solution à ce problème : des techniques d’analyse d’image plus classiques pourraient fonctionner. Il s’agira alors – du moins dans un premier temps – d’identifier et d’analyser le (ou les) *trait(s) de fracture*.

La détection de motifs géométriques dans une image en noir et blanc est un problème étudié depuis assez longtemps. Un algorithme populaire est celui de la transformée de Hough, d’abord brevetée en 1962 par Paul Hough[4] puis généralisée à la détection de lignes et courbes en 1972 par Richard Duda et Peter Hart[2].

Cependant, la détection de lignes dans une image est plus simple quand l’image est bien contrastée, et ne présente que les bords, et non – par exemple – des « lignes » dues à la porosité du tissu osseux sur des images radiographiques. En 1986, John F. Canny met au point un algorithme de détection des bords[1], qui permet de passer d’une image source à une image noir et blanc, où les pixels blancs font partie de bords et les pixels noirs non.

(⁵⁶²/650 mots)

6 Problématique retenue

Il s'agit d'étudier différents moyens de détection de fractures, et en particulier de comparer une approche par traitements d'images classiques à une approche avec réseaux neuronaux.

(²⁸/₅₀ mots)

7 Objectifs du TIPE

Je me propose :

- D'explorer la détection et classification sans apprentissage automatique, mais avec des techniques d'analyse d'image plus classiques (détection de bords, identification de segments de droites, calcul d'angles),
- D'utiliser un ou plusieurs réseaux neuronaux afin d'effectuer la même tâche, et
- De comparer les deux approches, en mettant en valeurs les avantages et inconvénients de chacune.

(⁵⁸/₁₀₀ mots)

Références

- [1] John F. CANNY. « A computational approach to edge detection ». eng. In : *IEEE transactions on pattern analysis and machine intelligence* 8.6 (juin 1986), p. 679-698. ISSN : 0162-8828. (Visité le 01/01/2022).
- [2] Richard O. DUDA et Peter E. HART. « Use of the Hough transformation to detect lines and curves in pictures ». In : *Commun. ACM* 15 (1972), p. 11-15. URL : <https://dl.acm.org/doi/10.1145/361237.361242> (visité le 30/12/2021).
- [3] William GALE et al. « Detecting hip fractures with radiologist-level performance using deep neural networks ». In : *arXiv :1711.06504 [cs, stat]* (nov. 2017). arXiv : 1711.06504. URL : <http://arxiv.org/abs/1711.06504> (visité le 30/12/2021).
- [4] Paul V C HOUGH. « Method and means for recognizing complex patterns ». Déc. 1962. URL : <https://patents.google.com/patent/US3069654A/en> (visité le 30/12/2021).
- [5] Tim JONES. *Machine learning and bias*. eng. Août 2019. URL : <https://developer.ibm.com/articles/machine-learning-and-bias/> (visité le 07/01/2022).
- [6] Simon C. MEARS. « Classification and Surgical Approaches to Hip Fractures for Nonsurgeons ». en. In : *Clinics in Geriatric Medicine* 30.2 (mai 2014), p. 229-241. ISSN : 07490690. DOI : 10.1016/j.cger.2014.01.004. URL : <https://linkinghub.elsevier.com/retrieve/pii/S0749069014000056> (visité le 30/12/2021).
- [7] MEDZCOOL. *Salter Harris Fracture Classification*. URL : <https://www.nucleotype.com/salter-harris-fractures> (visité le 20/12/2021).
- [8] Pranav RAJPURKAR et al. *MURA : Bone X-Ray Deep Learning Competition*. 2018. URL : <https://stanfordmlgroup.github.io/competitions/mura> (visité le 20/12/2021).
- [9] Pranav RAJPURKAR et al. *MURA : Large Dataset for Abnormality Detection in Musculoskeletal Radiographs*. 2018. arXiv : 1712.06957 [physics.med-ph]. (Visité le 20/12/2021).